

Previsão de Preços de Imóveis Residenciais com Aprendizado de Máquina

Um Estudo Comparativo entre Regressão Linear, Random Forest e Gradient Boosting Aplicado ao Dataset Ames Housing

Autores: Emerson Rosado Scalcon e Leandro Trevisan Martins **Disciplina:** Data Science **Curso:** Ciência da Computação **Instituição:** Universidade de Passo Fundo (UPF) **Data:** Junho de 2026

Repositório GitHub: <https://github.com/emersonscc/house-prices-ds>

1. Introdução

A precificação de imóveis residenciais é um problema de relevância econômica e social significativa. Para o comprador, identificar imóveis cujo preço esteja alinhado às suas características objetivas pode evitar pagamentos acima do valor de mercado. Para o vendedor, definir um preço de oferta competitivo é determinante para o tempo de venda. Para corretoras, instituições financeiras e seguradoras, a precificação automatizada é insumo crítico para análise de risco, concessão de crédito e avaliação patrimonial. Tradicionalmente, essa precificação é feita por avaliadores humanos com base em comparações e experiência. No entanto, a disponibilidade de bases de dados estruturadas com centenas de atributos por imóvel abre espaço para abordagens estatísticas e de aprendizado de máquina capazes de capturar padrões complexos que escapam à inspeção manual.

Este projeto aborda esse problema utilizando o dataset *House Prices: Advanced Regression Techniques*, disponibilizado pela plataforma Kaggle e referente a transações imobiliárias no município de Ames, Iowa (EUA). O objetivo é desenvolver e comparar diferentes modelos de regressão capazes de prever o preço de venda (**SalePrice**) de um imóvel a partir de 79 variáveis explicativas, incluindo área construída, ano de construção, qualidade dos materiais, características da garagem, condições do porão e localização (bairro).

O trabalho foi guiado por cinco hipóteses iniciais, formuladas a partir do conhecimento de domínio sobre o mercado imobiliário. Cada hipótese foi testada estatisticamente na fase de análise exploratória e suas conclusões orientaram as decisões de pré-processamento e modelagem:

1. **H1** — A área habitável (**GrLivArea**) é o fator de maior correlação individual com o preço.
2. **H2** — A qualidade geral do imóvel (**OverallQual**) tem impacto não-linear sobre o preço, com prêmio desproporcional para imóveis de qualidade superior.
3. **H3** — O bairro (**Neighborhood**) explica variações de preço mesmo entre imóveis de tamanho similar.
4. **H4** — A ausência de garagem está associada a preços sistematicamente menores.
5. **H5** — Imóveis mais novos tendem a apresentar preços maiores.

Além dessas questões substantivas, o projeto buscou demonstrar a aplicação prática do ciclo completo de Data Science: definição do problema, análise exploratória, pré-processamento e engenharia de variáveis, modelagem comparativa, avaliação crítica de resultados e comunicação por meio de relatório técnico e dashboard interativo.

2. Dataset

2.1. Origem e características

O dataset utilizado é o *Ames Housing*, compilado por Dean De Cock (Truman State University) em 2011 como alternativa ao tradicional *Boston Housing*. Os dados foram obtidos diretamente da Cidade de Ames, Iowa, e descrevem 1.460 transações imobiliárias residenciais ocorridas entre 2006 e 2010. Cada observação possui 79 variáveis explicativas e uma variável-alvo (**SalePrice**), totalizando 81 colunas. O dataset é disponibilizado publicamente pela competição *House Prices: Advanced Regression Techniques* na plataforma Kaggle.

2.2. Dicionário de variáveis (principais)

A tabela abaixo apresenta as variáveis de maior relevância no estudo. O dicionário completo está disponível no arquivo `data_description.txt` do repositório.

Variável	Tipo	Descrição
SalePrice	Numérica	Preço de venda do imóvel em USD (variável-alvo)
OverallQual	Ordinal (1-10)	Qualidade geral dos materiais e acabamento
OverallCond	Ordinal (1-10)	Condição geral do imóvel
GrLivArea	Numérica	Área habitável acima do solo (pés²)
TotalBsmtSF	Numérica	Área total do porão (pés²)
GarageCars	Numérica	Capacidade da garagem (número de veículos)
GarageArea	Numérica	Área da garagem (pés²)
YearBuilt	Numérica	Ano de construção original
YearRemodAdd	Numérica	Ano da última remodelação
FullBath	Numérica	Número de banheiros completos
Neighborhood	Categórica	Bairro (25 categorias)
MSZoning	Categórica	Classificação de zoneamento
LotArea	Numérica	Área do terreno (pés²)
KitchenQual	Ordinal	Qualidade da cozinha (Po a Ex)
ExterQual	Ordinal	Qualidade do acabamento externo

2.3. Etapas de limpeza, transformação e engenharia de features

O pré-processamento foi conduzido no notebook `02_preprocessing.ipynb` e seguiu as decisões orientadas pela análise exploratória.

Remoção de outliers. Foram removidas 2 observações identificadas na análise da hipótese H1: imóveis com área habitável superior a 4.000 pés² vendidos por menos de \$200.000. Tais observações representam vendas atípicas (possivelmente institucionais ou em condições especiais) e sua presença distorceria as linhas de regressão.

Tratamento de valores ausentes. Foi adotada uma estratégia contextualizada, reconhecendo que no dataset *Ames* a maioria dos valores `NaN` não representa dados faltantes, mas sim ausência do atributo descrito. Foram excluídas quatro variáveis com mais de 50% de ausência (`PoolQC`, `MiscFeature`, `Alley`, `Fence`), por carecerem de informação útil para a maioria dos imóveis. Variáveis categóricas remanescentes foram preenchidas com a categoria `None` quando `NaN` indicava ausência (ex.: `GarageType`, `BsmtQual`, `FireplaceQu`), e variáveis numéricas correspondentes foram preenchidas com `0` (ex.: `GarageArea`, `TotalBsmtSF`). Para as demais variáveis, foi utilizada imputação por moda (categóricas) ou mediana (numéricas).

Transformação da variável-alvo. A variável `SalePrice` apresenta assimetria positiva significativa ($skewness = 1,88$), com cauda longa à direita refletindo a presença de imóveis de alto valor. Foi aplicada a transformação `log1p(SalePrice)`, reduzindo a assimetria para 0,12 e aproximando a distribuição da normalidade — condição relevante para o desempenho da regressão linear.

Engenharia de features. Foram criadas sete novas variáveis com base no conhecimento de domínio:

- `TotalSF` = `TotalBsmtSF` + `GrLivArea` (área total da construção)
- `TotalBaths` = `FullBath` + `BsmtFullBath` + $0,5 \times (\text{HalfBath} + \text{BsmtHalfBath})$ (banheiros ponderados)
- `HouseAge` = `YrSold` - `YearBuilt` (idade do imóvel na venda)
- `YearsSinceRemod` = `YrSold` - `YearRemodAdd` (anos desde a última reforma)
- `HasGarage` = indicador binário de garagem
- `HasBasement` = indicador binário de porão
- `TotalPorchSF` = soma das áreas de varanda (aberta, fechada, três estações e tela)

A feature `TotalSF` se destacou ao atingir correlação de 0,82 com `SalePrice`, superando todas as variáveis originais — incluindo `GrLivArea` (0,71) e `OverallQual` (0,79).

Codificação de variáveis categóricas. Para variáveis ordinais relacionadas à qualidade (`ExterQual`, `KitchenQual`, `BsmtQual` etc.), foi aplicado mapeamento manual preservando a ordem semântica (`None=0`, `Po=1`, `Fa=2`, `TA=3`, `Gd=4`, `Ex=5`). Para variáveis nominais com até 10 categorias, foi aplicado One-Hot Encoding com `drop_first=True`. Variáveis nominais de alta cardinalidade (acima de 10 categorias) foram excluídas para reduzir a dimensionalidade.

Normalização. Foi aplicado `StandardScaler` (média 0, desvio padrão 1) para padronizar as escalas das variáveis numéricas, condição importante para a regressão linear e regressão Ridge. O `fit` do scaler foi feito exclusivamente no conjunto de treino para evitar *data leakage*, sendo apenas `transform` aplicado ao conjunto de validação.


Divisão treino/validação. A base foi dividida em 80% para treino (1.166 amostras) e 20% para validação (292 amostras), com `random_state=42` para garantir reprodutibilidade. O conjunto final possui 56 variáveis preditoras.

3. Análise Exploratória

3.1. Distribuição da variável-alvo


A análise inicial do `SalePrice` revelou uma distribuição fortemente assimétrica à direita (Figura 1). A mediana (\$163.000) é significativamente inferior à média (\$180.921), e a cauda longa estende-se até \$755.000. A

transformação logarítmica aplicada no pré-processamento corrigiu essa assimetria, tornando a distribuição aproximadamente normal e adequada para modelos lineares.



3.2. Correlações com a variável-alvo


A análise de correlação de Pearson entre as 38 variáveis numéricas e o **SalePrice** identificou que **OverallQual** ($r = 0,79$) e **GrLivArea** ($r = 0,71$) são os preditores mais fortes (Figura 2). Esse resultado reverte parcialmente a hipótese H1: a qualidade percebida supera o tamanho físico como variável explicativa individual mais relevante. Em terceiro e quarto lugar aparecem **GarageCars** e **GarageArea**, antecipando a confirmação de H4.




3.3. Teste das hipóteses

H1 — Área habitável (GrLivArea). A relação é forte e positiva, mas duas observações destoam claramente do padrão (Figura 3): imóveis com área superior a 4.500 pés² vendidos por menos de \$200.000. Tratam-se de


outliers removidos no pré-processamento. A correlação observada foi $r = 0,709$, confirmando a hipótese em termos de força, mas com a ressalva de que **OverallQual** apresenta correlação superior.




H2 — Qualidade geral (OverallQual). O boxplot por nível de qualidade (Figura 4) revela claramente o efeito não-linear: enquanto a transição da qualidade 5 para 6 representa aumento mediano de \$40.000, a transição de 9 para 10 representa aumento superior a \$80.000. O gráfico de mediana à direita confirma o padrão exponencial. Esta descoberta é particularmente importante para a modelagem, pois indica que modelos lineares enfrentarão limitação nesta variável, beneficiando os modelos baseados em árvores.




H3 — Bairro. Para isolar o efeito do bairro do efeito do tamanho, foram analisadas apenas casas com área entre 1.264 e 1.664 pés² ($n = 461$). O preço mediano variou de \$115.000 (MeadowV) a \$265.000 (NoRidge), uma variação de 2,3 vezes (Figura 5). A hipótese é claramente confirmada: localização explica variações substanciais de preço independentemente do tamanho.



H4 — Garagem. A diferença entre imóveis com e sem garagem foi expressiva: mediana de \$175.000 para os primeiros contra \$105.000 para os segundos, diferença de aproximadamente 67% (Figura 6). Vale notar que apenas 81 dos 1.460 imóveis (5,5%) não possuem garagem, o que torna essa categoria minoritária mas com impacto claro no preço.



H5 — Ano de construção. A correlação entre **YearBuilt** e **SalePrice** foi de 0,52 (Figura 7), indicando associação moderada. A análise por década evidencia uma valorização acentuada para imóveis construídos a partir dos anos 2000, sugerindo que critérios construtivos modernos e a presença de tecnologias atuais agregam valor além da idade isoladamente.



3.4. Síntese da análise exploratória

A EDA permitiu identificar padrões consistentes, validar parcialmente quatro das cinco hipóteses e ajustar a interpretação da quinta. Mais importante, gerou três decisões metodológicas para a modelagem: (i) transformação logarítmica da variável-alvo, (ii) remoção dos dois outliers de `GrLivArea` e (iii) priorização da feature `OverallQual` no entendimento do problema. A análise também antecipou que modelos lineares teriam limitações por causa da relação exponencial de `OverallQual`, motivando a inclusão de modelos baseados em árvores na fase de modelagem.

4. Modelagem

4.1. Seleção dos modelos

Foram escolhidos quatro modelos representando três famílias distintas de algoritmos de regressão, com o objetivo de comparar abordagens lineares e não-lineares:

Regressão Linear (OLS). Modelo de referência (baseline) que assume relação linear entre as features e o alvo. É interpretável e computacionalmente simples. Sua inclusão permite quantificar o ganho real obtido com modelos mais complexos.

Regressão Ridge (L2). Variante da regressão linear com regularização L2 sobre os coeficientes (`alpha=10`). Foi incluída para verificar se a multicolinearidade entre features (esperada em datasets com muitas variáveis correlacionadas, como áreas e qualidades) afeta significativamente os resultados.

Random Forest Regressor. Ensemble de árvores de decisão treinadas em subconjuntos aleatórios dos dados (*bagging*). Robusto a outliers e capaz de capturar relações não-lineares e interações entre variáveis sem necessidade de transformações prévias. Configuração: `n_estimators=300`, `max_depth=15`, `min_samples_leaf=3`.

Gradient Boosting Regressor. Ensemble que constrói árvores sequencialmente, com cada nova árvore corrigindo os erros residuais das anteriores. Geralmente apresenta a melhor performance em datasets tabulares de tamanho médio. Configuração: `n_estimators=500`, `learning_rate=0.05`, `max_depth=4`, `subsample=0.8`. O parâmetro `subsample` introduz componente estocástico que atua como regularização implícita.

4.2. Protocolo de treinamento e validação

Todos os modelos foram treinados sobre o mesmo conjunto de treino normalizado (1.166 amostras, 56 features) tendo `log1p(SalePrice)` como variável-alvo. A avaliação foi realizada de três formas complementares:

- 1. **Conjunto de validação (holdout)** — 292 amostras separadas no início do pré-processamento, nunca utilizadas no treinamento.
- 2. **Validação cruzada (5-fold)** — aplicada exclusivamente sobre o treino, para verificar a estabilidade da performance.
- 3. **Inspeção dos resíduos** — análise gráfica da relação entre valores preditos e reais, e da distribuição dos resíduos, para detectar problemas sistemáticos.

As métricas adotadas foram **RMSE** (raiz do erro quadrático médio, em USD), **MAE** (erro absoluto médio, em USD) e **R²** (coeficiente de determinação). Para reporte ao usuário final, as predições foram revertidas para o espaço original via `expm1()`, permitindo interpretação direta dos erros em dólares.


5. Resultados e Discussão

5.1. Comparação geral entre modelos

A Tabela 1 sintetiza os resultados dos quatro modelos.

Tabela 1 — Comparação de performance entre modelos

Modelo	RMSE Treino	RMSE Validação	MAE Validação	R ² Treino	R ² Validação	CV RMSE (log)
Regressão Linear	\$21.551	\$21.307	\$15.490	0,9117	0,8996	0,1273
Ridge (L2)	\$21.559	\$21.333	\$15.523	0,9117	0,8994	0,1268
Random Forest	\$14.246	\$24.613	\$16.947	0,9672	0,8615	0,1405
Gradient Boosting	\$5.867	\$20.715	\$14.918	0,9931	0,8961	0,1282



O **Gradient Boosting** apresentou o melhor desempenho no conjunto de validação, com RMSE de \$20.715 e MAE de \$14.918. Considerando que o preço médio dos imóveis é de aproximadamente \$180.000, o erro absoluto médio representa cerca de 8% do valor de venda — patamar considerado adequado para aplicações de avaliação automatizada de imóveis.

5.2. Discussão crítica dos resultados

A análise comparativa revela quatro pontos relevantes que merecem aprofundamento:

Diagnóstico de overfitting no Random Forest. O caso do Random Forest exemplifica de maneira clara o problema de overfitting. O modelo apresentou RMSE de treino de apenas \$14.246 (segundo melhor) mas o pior desempenho na validação (\$24.613). Essa lacuna de aproximadamente \$10.000 entre treino e validação indica que o modelo memorizou padrões específicos dos dados de treinamento que não generalizam para novos casos. A configuração utilizada (`max_depth=15`) permite árvores profundas demais, e mesmo `min_samples_leaf=3` não foi suficiente para conter o sobreajuste.


Regularização implícita no Gradient Boosting. Em contraste, o Gradient Boosting apresenta RMSE de treino ainda menor (\$5.867) — sinal de capacidade de ajuste superior — mas generaliza melhor na validação (\$20.715). A diferença está nos mecanismos de regularização: `learning_rate=0.05` força o modelo a aprender em passos pequenos, e `subsample=0.8` introduz aleatoriedade no treinamento de cada árvore. Esses elementos atuam como regularização implícita.

Robustez da Regressão Linear. A performance da Regressão Linear (\$21.307 de RMSE) ficou apenas \$592 acima do Gradient Boosting. Esse resultado surpreende positivamente e tem implicação prática importante: para muitos casos de uso, um modelo linear simples e interpretável pode ser preferível ao Gradient Boosting, pois oferece transparência (cada coeficiente é diretamente legível) ao custo de erro adicional inferior a 3% sobre o melhor modelo. O resultado também sugere que o feature engineering do pré-processamento — em particular a criação de `TotalSF` — capturou boa parte das não-linearidades, deixando às variáveis remanescentes um comportamento aproximadamente linear.

Multicolinearidade não é problema crítico. A Regressão Ridge produziu resultado virtualmente idêntico à Regressão Linear (\$21.333 vs \$21.307), indicando que a multicolinearidade entre features não está afetando significativamente a estabilidade dos coeficientes lineares. A regularização L2 não trouxe benefício mensurável neste cenário.


5.3. Análise de resíduos do melhor modelo

A inspeção dos resíduos do Gradient Boosting (Figura 9) confirma o comportamento adequado do modelo. O gráfico Real × Predito mostra alinhamento próximo da reta de identidade em toda a faixa de preços. A distribuição dos resíduos é aproximadamente simétrica e centrada em zero, sem indícios de viés sistemático. Existem alguns resíduos negativos expressivos na faixa de preços altos (acima de \$300.000), indicando que o modelo subestima imóveis muito caros — comportamento esperado, dado que esta faixa está sub-representada nos dados de treinamento (cauda longa da distribuição).



5.4. Importância das features

A Figura 10 apresenta a importância das features para os dois modelos baseados em árvores. O resultado fecha o ciclo da análise iniciada na EDA de forma elegante.



No **Random Forest**, **OverallQual** lidera com aproximadamente 40% da importância total, confirmando definitivamente a relevância identificada na hipótese H2. No **Gradient Boosting**, **TotalSF** aparece em primeiro lugar com 35%, validando a engenharia de features realizada no pré-processamento — a variável criada superou todas as variáveis originais isoladas. Em ambos os modelos, apenas duas variáveis (**OverallQual** e **TotalSF**) respondem por aproximadamente 70% da importância total, indicando que o problema de precificação imobiliária no dataset *Ames* é dominado por dois fatores principais: qualidade percebida e área total construída.

6. Conclusão

Este trabalho desenvolveu um sistema de previsão de preços imobiliários, percorrendo todas as etapas do ciclo de Data Science aplicado ao dataset *Ames Housing*. A partir de cinco hipóteses iniciais sobre o mercado imobiliário, foram realizadas análise exploratória aprofundada, pré-processamento com engenharia de sete novas features, treinamento comparativo de quatro modelos de regressão e construção de dashboard interativo para comunicação dos resultados.

O modelo final escolhido — **Gradient Boosting Regressor** — atingiu RMSE de validação de \$20.715 e MAE de \$14.918, representando aproximadamente 8% do preço médio dos imóveis. As cinco hipóteses iniciais

foram confirmadas (quatro plenamente e uma parcialmente), e a análise de importância das features revelou que o problema é dominado por dois fatores: qualidade percebida (**OverallQual**) e área total construída (**TotalSF**). A engenharia de features foi particularmente bem-sucedida — **TotalSF**, variável criada a partir da soma da área do porão e da área acima do solo, apresentou correlação superior a qualquer variável original ($r = 0,82$) e foi a feature mais importante para o modelo vencedor.

6.1. Limitações

O trabalho apresenta limitações que devem ser explicitadas. A primeira é a **especificidade geográfica e temporal** dos dados: o dataset cobre apenas o município de Ames, Iowa, entre 2006 e 2010. Os modelos treinados não devem ser generalizados para outros mercados ou períodos sem novo treinamento. A segunda é a **sub-representação de imóveis de alto valor**: a cauda direita da distribuição de preços contém poucas observações, o que limita a capacidade dos modelos de prever com precisão imóveis acima de \$300.000. A terceira é a **ausência de variáveis macroeconômicas externas**, como taxa de juros, inflação imobiliária ou indicadores de desenvolvimento regional, que poderiam enriquecer o modelo. A quarta é a **adoção de configurações conservadoras de hiperparâmetros**, sem busca sistemática (grid search ou bayesiana), o que provavelmente deixa margem para melhoria marginal na performance.

6.2. Sugestões para trabalhos futuros

A partir das limitações identificadas, sugerem-se três direções para extensão do trabalho:

Otimização de hiperparâmetros. A aplicação de busca sistemática (**GridSearchCV** ou otimização bayesiana via Optuna) sobre o Gradient Boosting poderia reduzir o RMSE em margem relevante. A configuração conservadora atual privilegiou estabilidade sobre performance máxima.

Stacking de modelos. A combinação das predições dos quatro modelos via meta-aprendizado (modelo de segundo nível treinado sobre as predições) é uma técnica conhecida por reduzir o erro residual em datasets tabulares e seria uma extensão natural deste trabalho.

Incorporação de dados externos. A inclusão de variáveis macroeconômicas, como o índice nacional de preços imobiliários (FHFA House Price Index) e a taxa de juros hipotecária no período de cada venda, poderia capturar variações sistemáticas atribuíveis ao contexto econômico que escapam aos atributos físicos do imóvel.

Referências

Cock, D. D. (2011). Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project. *Journal of Statistics Education*, 19(3).

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Kaggle. *House Prices: Advanced Regression Techniques*. Disponível em: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>. Acesso em: junho de 2026.